

Utilização de Sistemas de Recomendação em Filmes/Música e em Hotelaria/Restauração

Universidade do Minho, Braga, Portugal

Resumo Os sistemas de recomendação são ferramentas e técnicas de software que oferecem sugestões de itens a um utilizador [1]. Qualquer pessoa já teve de passar por um processo em que de um conjunto alargado de hipóteses teve de fazer uma escolha, não tendo qualquer forma de saber qual a mais adequada sem as rever todas meteticulosamente. Também há situações em que não existe informação suficiente para formar uma opinião sobre todas as hipóteses. Um sistema de recomendação é algo que nos facilita esse tipo de decisões de enorme dificuldade, utilizando o conhecimento que tem acerca do utilizador para tentar prever qual a escolha que o mesmo faria caso tivesse uma sabedoria aprofundada acerca da decisão que tem a fazer. Caso falhe esta previsão, estará, em princípio a dar uma sugestão não ideal, mas útil, e a aproximar-se cada vez mais da capacidade de fornecer as recomendações perfeitas àquele indivíduo. Já passaram mais de 15 anos desde que os primeiros sistemas deste tipo foram implementados e a realidade é que hoje em dia fazem parte do nosso quotidiano e estão presentes nas mais diversas áreas: instrumentos financeiros, imobiliária, consumíveis, notícias, redes sociais, política e muitos mais [1]. Sugestões vindas de uma fonte confiável são uma componente extremamente valiosa em processos de tomada de decisão, daí os sistemas de recomendação serem uma tecnologia altamente relevante e o investimento nos mesmos faz com que tenham uma enorme evolução pela frente.

Palavras-chave: Sistemas de Recomendação · Filmes · Música · Hotelaria · Restauração

1 Paradigmas de Sistemas de Recomendação

1.1 Os diversos paradigmas

No que toca a aprendizagem, é possível identificar quatro paradigmas de computação que servem de base para a construção de Sistemas de Recomendação:

1. Sistemas de Aprendizagem
2. Aprendizagem com Supervisão
3. Aprendizagem sem Supervisão
4. Aprendizagem por Reforço

Primeiramente, **Sistemas de Aprendizagem**, é um paradigma de computação que define um sistema capaz de adquirir conhecimento de forma autónoma

e independente, sem ser explicitamente programado nesse sentido. Esta abordagem é conhecida por *Machine Learning*.

Dentro da abordagem acima mencionada, temos o paradigma de **Aprendizagem com Supervisão**. Neste tipo de sistemas, estão disponíveis casos exemplo e são utilizados algoritmos de modo a descobrir a *mapping function* (função de mapeamento) que transforma os dados de *input* no *output*. O método utilizado tem como objetivo a otimização da função ao máximo e, dado *input data*, retornar valores o mais aproximado possíveis aos pretendidos [2].

Estes tipos de problemas podem ser divididos em duas categorias: Problemas de **Classificação** (para *outputs* de natureza discreta) e Problemas de **Regressão** (para *outputs* de natureza contínua). De entre os vários algoritmos existentes usualmente implementados (*Random Forest*, *Naive Bayes*, *Decision trees*, *Bagged trees*, entre outros) destacam-se *Linear Regression* em dados contínuos e *Support vector machines* em dados discretos.

Em oposição, nos sistemas baseados em **Aprendizagem sem Supervisão**, apenas é inserida *input data* sem os *outputs* correspondentes. Nestes casos, a aprendizagem passa pela análise do funcionamento interno do sistema, nomeadamente, por **Segmentação/Clustering** (distribuição dos dados por grupos com base nas suas características, e.g. clientes que comprem um certo produto) ou **Associação** (identificação de regras de comportamento, e.g. clientes que comprem o produto X tendem a comprar o produto Y).

Alguns exemplos notórios de algoritmos de Aprendizagem sem Supervisão são *k-means* para problemas de Segmentação, cujo propósito é a partição de n observações em k *clusters*/grupos (em que cada dado pertence ao *cluster* mais próximo da média), **Apriori** para problemas de Associação, no qual se procede à identificação de itens de elevada frequência na base de dados, e se vai alargando para grupos cada vez maiores de *item sets* (desde que a sua frequência também seja alta).

Por fim, **Aprendizagem por Reforço**, é um paradigma de computação que implica a ausência de *outputs* pretendidos tal como acontece na Aprendizagem sem Supervisão. No entanto, difere neste no comportamento. Os seus algoritmos usam técnicas de auto-alimentação de sinais, que refletem o (in)sucesso do sistema num todo após a execução de certas ações, ao contrário dos algoritmos supervisionados cujo *feedback* é dado após cada ação e por um professor/treinador [4].

2 Técnicas de machine learning utilizadas

Para um Sistema de Recomendação ser eficaz, é necessário que identifique corretamente quais os itens de interesse para o utilizador, isto é, prever o que este necessita, procura e irá gostar de entre as várias opções disponíveis. Desde modo, o sistema deve ser capaz de conseguir avaliar e posteriormente comparar itens entre si, e tomar uma decisão em conformidade.

Com este fim, os sistemas de recomendação usam várias técnicas de *Machine Learning*, sendo divididos em cinco tipos principais: [1]

1. *Content-based filtering*
2. *Collaborative filtering*
3. *Demographic*
4. *Knowledge-based recommenders*
5. *Hybrids Systems*

Content-based Filtering, em português “Filtragem baseada em conteúdo” é, como o nome indica, uma técnica de *Machine Learning* na qual os sistemas recomendam produtos com características semelhantes aos que há registo que o utilizador tenha gostado. Usualmente, são associadas palavras-chave a cada item disponível, bem como ao utilizador conforme o seu comportamento na plataforma e, posteriormente, são-lhe feitas sugestões de opções com *keywords* que possua. Um exemplo comum é a recomendação de um filme do mesmo género de um cujo cliente já tenha comprado bilhetes/dado uma boa crítica [3].

Um das técnicas mais implementadas em sistemas recomendação é **Collaborative Filtering**, ou seja, Filtragem Colaborativa. Este tipo de filtragem é muito semelhante à referida anteriormente (*Content-based Filtering*), na medida em que analisa os gostos de cada *user*. Com esta informação, compara os utilizadores entre si, e recomenda-lhes produtos que *users* com gostos semelhantes tenham gostado. Isto é, assume que se dois clientes possuem um histórico semelhante no sistema, a probabilidade de um deles gostar de um item de interesse para o outro é elevada. Um exemplo muito comum é a secção (em sites de venda online) de “*Costumers Who Bought This Item Also Bought*” [5].

Outra abordagem utilizada é a recomendação de itens a partir de Informação **Demográfica** (como por exemplo idade, género, estado civil, nacionalidade, entre outros) baseando-se no princípio de que cada nicho demográfico possui gostos particulares. Esta técnica é particularmente útil quando um utilizador é novo no sistema e, portanto, ainda não possui *user data* associada [6].

Por outro lado, temos os sistemas **Knowledge-based** (recomendação baseada em conhecimento), os quais se baseiam em informação específica sobre o domínio e a descrição do problema, bem como as necessidades e preferências do utilizador e a utilidade de um item para o mesmo. Exemplificando, a especificação de características pretendidas num carro, numa plataforma de vendas online.

Por fim, temos os **Hybrids Systems**, isto é, sistemas de recomendação que combinam mais do que uma das técnicas de *Machine Learning* acima mencionadas com o objetivo de eliminar alguns problemas, como é o caso do *cold start* (ausência de informação suficiente para recomendações a novos utilizadores), ou até mesmo casos de itens cuja descrição em *keywords* seja difícil de atribuir o que é um problema para *Content-based Filtering* [7].

3 Sistemas de Recomendação para Filmes e Músicas

3.1 Vantagens para o promotor

Hoje em dia, um sistema de recomendação possui vários objetivos semelhantes para serviços que disponibilizem filmes ou músicas. Podemos identificar vários

objetivos principais. O primeiro passa por melhorar a retenção de utilizadores, isto é, fazer com que os clientes continuem subscritores do serviço. No caso da plataforma da *Netflix*, se o cliente achar que as recomendações de filmes que recebe são bastante precisas, é altamente improvável que este mude para outro serviço. Em segundo lugar, aumentar as receitas, como por exemplo no caso do *Youtube*. As receitas do *Youtube* provêm principalmente das publicidades nos vários vídeos. Assim, se ao utilizador forem recomendados vídeos que este veja, o sistema de recomendação estará a aumentar as receitas. Por fim, o próprio uso de sistemas de recomendação por parte dos utilizadores permite aos fornecedores dos serviços economizar tempo através da recolha de uma grande quantidade de dados úteis [17,18].

3.2 Vantagens para o alvo

No caso das plataformas que disponibilizam filmes, nomeadamente a *Netflix*, existem várias vantagens que os sistemas de recomendações dão ao utilizador. Um estudo revelou que um típico utilizador da *Netflix* perde o interesse após 60 a 90 segundos de pesquisa, sendo bastante provável que o utilizador saia da plataforma. Um bom sistema de recomendação resolve esse problema, indicando qual o filme que o utilizador deve ver sem que este perca tempo com a pesquisa do mesmo [13].

No caso por exemplo, do *Spotify*, um serviço fornecedor de músicas, este consegue fazer recomendações bastante precisas mesmo que o cliente tenha o gosto musical mais peculiar possível e que só existam, por exemplo, 20 pessoas como ele. Estas recomendações são feitas através do sistema de recomendação *Discover Weekly*, onde no início de cada semana todos os utilizadores do *Spotify* recebem um conjunto de 30 músicas escolhidas tendo em conta o gosto do utilizador [19].

3.3 Exemplos de sistemas de recomendação para filmes

Nos dias de hoje, muitas pessoas querem ver os seus filmes preferidos quando quiserem e onde quiserem. Desta forma, surgiu a plataforma *Netflix* que disponibiliza aos seus clientes filmes e séries de televisão. Em 2015, a *Netflix* já possuía 65 milhões de membros que visualizaram, no seu conjunto, mais de 100 milhões de horas de filmes e séries de televisão [13,14].

Destes números conclui-se que a *Netflix* tem acesso a uma grande quantidade de dados, nomeadamente o que cada cliente vê, como vê, a secção na plataforma da *Netflix*, no qual o cliente descobriu o filme/série, e até as recomendações que são ignoradas. Informações como clientes com gostos semelhantes, sobre os filmes em si, e também aspetos como a que hora do dia o cliente usa a plataforma e durante quanto tempo a usa são também relevantes. Assim, estes dados são todos usados para o sistema de recomendação que é baseado numa série de diferentes algoritmos que compõem a maior parte da página inicial da *Netflix* [13,16].

Vários algoritmos são usados de forma a dar os melhores e diferentes tipos de recomendações aos cliente, tais como *Trending Now* ou *Video-Video Similarity*. No caso das recomendações do tipo *Trending Now*, a *Netflix* descobriu

que tendências em curtos espaços de tempo (minutos ou poucos dias) quando combinados com os dados sobre o utilizador, tornam-se uma ferramenta altamente precisa no que toca a prever o que o utilizador vai visualizar. Dentro deste contexto, há dois tipos de tendências que a *Netflix* consegue prever com mais precisão. Por um lado, todas aquelas que se repetem ciclicamente (ano a ano, por exemplo), mas têm um impacto de curto prazo, como por exemplo filmes referentes ao Dia de São Valentim. Por outro lado, todas aquelas que são causadas por eventos únicos, mas mais uma vez com um impacto de curto prazo e com grande cobertura por partes dos média, como por exemplo um desastre natural, causando assim um elevado e súbito interesse em documentários sobre desastres naturais [13].

Também existem outros tipos de recomendações, como a *Video-Video Similarity*. Neste tipo de recomendação, a plataforma gera recomendações através de um filme que o utilizador tenha visto, combinado com os dados sobre o utilizador. O algoritmo em si começa por encontrar subconjuntos de filmes semelhantes ao que o utilizador visualizou, mas numa segunda fase, só são apresentadas recomendações personalizadas ao utilizador, isto é, tendo em conta os dados sobre o cliente, estimando assim qual o subconjunto de filmes relacionados que o utilizador vai gostar mais [13].

Por fim, muitas destas recomendações são baseadas em técnicas de filtragem colaborativa, que permitem fazer boas previsões quanto ao que o utilizador vai visualizar. No entanto, existem também desvantagens pois ao recolher e processar as preferências de vários utilizadores, está-se a criar um potencial local de fuga de informação privada sobre os utilizadores, sendo por isso necessário usar estas técnicas com precaução [14,15].

3.4 Exemplos de sistemas de recomendação para músicas

O famoso serviço da *Spotify* até Julho de 2015, pelo menos oficialmente, não utilizava sistemas de recomendação. Foi então que introduziu as listas de reprodução "*Spotify's Discover Weekly*". O sistema utiliza métodos de filtragem colaborativa, ou seja, utiliza os gostos de outros utilizadores para determinar as melhores previsões para um determinado utilizador. Através de algoritmos baseados em memória, também conhecidos como algoritmos do vizinho mais próximo, são listadas as músicas que o utilizador-alvo ouve e o sistema encontra outros utilizadores que têm os gostos mais "próximos" (i.e.: que ouvem mais músicas em comum), passando então a recomendar ao utilizador-alvo as músicas que os outros ouvem e que este ainda não ouviu [8].

No entanto, este método tem desvantagens, como necessitar de outros utilizadores com gostos semelhantes para fazer boas recomendações e dificultar a exposição de músicas ou artistas novos, pois ainda ninguém os ouve. Em contraste, existe a abordagem peculiar da *Pandora*, um serviço de *streaming* de música semelhante ao *Spotify*, que contratou milhares de musicólogos para desenvolver o "*Music Genome Project*", em que todas as músicas são classificadas a partir de aproximadamente 400 atributos musicais que coletivamente descrevem a música na sua essência. Esta classificação das músicas, para já, é executada

manualmente pelos musicólogos, sendo este um processo extremamente rigoroso e tedioso, que dura em média 20 minutos por música, daí a necessidade de empregar tantas pessoas para essa função o que torna o processo extremamente dispendioso. Assim que as músicas estão devidamente classificadas na base de dados, já é possível calcular a proximidade entre as próprias músicas, em vez da proximidade entre gostos de utilizadores. Também são aqui utilizados algoritmos do vizinho mais próximo [9].

Isto faz com que, saber de que músicas um utilizador gosta seja suficiente para lhe oferecer recomendações úteis sem depender de outros utilizadores e do reconhecimento que a música já tem, o que é muito mais benéfico para os dois tipos de utilizadores. O ouvinte, porque terá muito mais probabilidade de ouvir músicas que nunca ouviu mesmo fora do *Pandora* e o produtor da música, pois a recomendação será menos à base de fama, logo, mais justa. Os resultados desta abordagem estão à vista no contentamento dos utilizadores da plataforma.

4 Sistemas de Recomendação para Hotelaria e Restauração

4.1 Vantagens para o promotor

No ramo da hotelaria pretende-se que a informação chegue a potenciais clientes de uma forma relevante e de acordo com os seus interesses. Assim, um sistema de recomendação deste género permite que os clientes encontrem com facilidade aquilo que procuram, maximizando a hipótese de efetuarem reservas de várias viagens com diferentes tipos de alojamento. Por sua vez, toda esta informação atinge um grande número de pessoas de uma maneira cómoda para o promotor, não sendo necessário para este a contratação de um elevado número de colaboradores para o mesmo efeito [11].

Através dos sistemas de recomendação, os estabelecimentos envolvidos na área da restauração podem dinamizar os seus serviços de um modo bastante cómodo através de aplicações ou de *websites*. Este aspeto é bastante útil principalmente quando se trata de estabelecimentos recentes que necessitam de atrair clientes que procuram novas experiências na área da restauração. É também bastante proveitoso para selecionar certos tipos de público alvo, principalmente se o tipo de comida servida no restaurante for de um tipo específico, como a comida vegetariana ou tailandesa, por exemplo [12].

4.2 Vantagens para o alvo

No que diz respeito à hotelaria e viagens, os turistas nem sempre conseguem obter todas as informações que pretendem acerca de um determinado destino e possíveis alojamentos. Isto acontece especialmente em destinos onde há uma grande diferença a nível cultural e da língua materna. Por outro lado, os sistemas de recomendação permitem aos turistas viagens mais flexíveis e mais de acordo com os seus interesses por oposição aos serviços fornecidos nas agências

de viagem, onde nem sempre os destinos pretendidos coincidem com as datas mais adequadas aos turistas [10].

Os sistemas de recomendação trazem bastantes vantagens aos clientes na área da restauração. Estes sistemas podem ajudar os diversos clientes a escolherem os restaurantes mais conceituados de uma certa cidade de acordo com as críticas efetuadas por outros clientes. Além disso é útil no caso de clientes com certos tipos de problemas relacionados com a alimentação, como por exemplo a intolerância à lactose e/ou glúten, ajudando que estes encontrem restaurantes adequados às suas necessidades. Os clientes podem facilmente encontrar restaurantes que sirvam um determinado tipo de comida específica ou que possuam certos tipos de menus, como os menus de dieta [12].

4.3 Exemplos de sistemas de recomendação utilizados em hotelaria

Um projeto interessante neste contexto é uma aplicação chamada *TripBuddy* desenvolvida na Universidade de Bina Nusantara na Indonésia. O *TripBuddy* permite que um utilizador faça um plano completo de uma viagem, dando a possibilidade de o utilizador escolher, para cada um dos seus destinos pretendidos, todos os locais onde ficará alojado. Além disso, esta aplicação oferece vários tipos de pesquisas bastante versáteis e detalhadas e permite que o utilizador expresse o seu grau de satisfação sobre um eventual destino/alojamento que já tenha visitado, podendo então esta crítica influenciar os interesses de outros utilizadores [10].

As funcionalidades descritas acima tornam esta aplicação bastante semelhante a outras já desenvolvidas e bastante populares nesta vertente (como por exemplo o *Trivago* e o *TripAdvisor*). No entanto, o *TripBuddy* complementa estas aplicações fornecendo sugestões de destinos e alojamento ao utilizador de acordo como os dados de eventuais pesquisas efetuadas no *browser* deste, assim como de eventuais viagens realizadas por parte do utilizador. Esta componente é útil já que se foca nos interesses de uma pessoa em específico e não apenas em sugestões baseadas de acordo com os interesses de terceiros. Adicionalmente, a aplicação calcula o caminho mais curto e eficiente para se percorrer todos os destinos presentes na viagem. Esta componente é bastante apelativa para pessoas que realizam viagens com um grande número de destinos, como por exemplo voltas ao mundo e *interrails*. Finalmente, é dada a opção de o utilizador consultar o seu plano completo de viagem em modo *offline*.

As sugestões fornecidas ao utilizador são calculadas através do algoritmo *K-Means* de *machine learning*. Cada utilizador possui um conjunto de atributos que representam uma certa categoria, tais como preço, localização e classificações de um destino. Os pesos desses atributos vão sendo modificados para cada utilizador de acordo com as suas pesquisas passadas, eventuais destinos semelhantes aos que o utilizador já visitou e de acordo com as análises de outros turistas a certos locais e alojamentos. Deste modo, torna-se bastante provável que um utilizador receba sugestões relevantes de diversos destinos e alojamentos que estejam em conformidade com os seus interesses.

4.4 Exemplos de sistemas de recomendação utilizados na restauração

No ramo da restauração existem muitas aplicações com o intuito de encontrar/pesquisar restaurantes, no entanto, para já não existem grandes exemplos de sistemas de recomendação inteligentes, principalmente por incapacidade de adquirir dados do utilizador. As recomendações destes sistemas, como por exemplo o *TripAdvisor*, o *Zomato*, a *Yelp* e a *Foursquare*, são baseadas somente nos parâmetros de pesquisa introduzidos pelo utilizador, pela sua localização ou pelos estabelecimentos que pagam por destaque.

Contudo, existe um serviço que se distingue no seu investimento no sistema de recomendação, principalmente por ter um retorno maior cada vez que um cliente escolhe um estabelecimento: a *Uber Eats*. As suas recomendações são baseadas nos gostos dos seus utilizadores, modelados a partir de *machine learning* e na interpretação semântica atribuída pela plataforma aos diferentes tipos de comida. Aquando do lançamento do primeiro sistema de recomendação da plataforma, em julho de 2016, o foco deste era de simplesmente otimizar a probabilidade do utilizador fazer uma encomenda. No entanto, começaram a notar que, conforme a plataforma crescia e tinha mais estabelecimentos associados, os novos estabelecimentos, mesmo sendo famosos, não estariam a ter o número de pedidos que seria expectável. Daí terem tomado a decisão de criar um método diferente, dado que sabiam que nem todos os restaurantes estariam a receber justamente o destaque, o que eventualmente resultaria num decréscimo no número de estabelecimentos parceiros, o que poderia resultar na diminuição de clientes por falta de diversidade.

Para equilibrar as necessidades entre os seus restaurantes e os seus clientes, a *Uber* utiliza otimização multi-objetivo, um método de tomada de decisão que procura otimizar mais que uma função objetivo simultaneamente. Um dos fatores que a empresa considerou relevante maximizar foi a diversidade das recomendações. Isto porque, consideram importante que, por exemplo, um utilizador que em todos os seus pedidos realizados até agora fossem de restaurantes italianos, não receba apenas recomendações desse tipo de cozinha. Portanto, as recomendações a esse utilizador deveriam sim ser relevantes, apresentando o tipo de comida que ele mais gostasse, mas também, diversificadas, dando-lhe a conhecer novas experiências. Foi então desenvolvido um algoritmo personalizado de diversificação, que trata o perfil de gostos do cliente e o perfil do restaurante sob formas vetoriais e otimiza o objetivo conjunto da relevância e da diversidade.

Outra preocupação da empresa encontrava-se em maximizar a probabilidade de um cliente voltar a fazer pedidos na *Uber Eats*, daí querer ser capaz de prever se um determinado restaurante vai agradar ou não um determinado cliente. Incluir como função objetivo a satisfação do cliente é mais complicado do que fazer-lo com a diversidade e com a relevância, pois saber se um determinado cliente vai ou não voltar a fazer uma encomenda não é um conhecimento que se adquira no imediato. Como resolução ao problema, foi desenvolvido um modelo de *machine learning* para prever a probabilidade de um cliente voltar a fazer pedidos na plataforma se agora a sua encomenda for feita num determinado

estabelecimento, baseado em atributos dos pedidos passados, tanto do cliente como do restaurante, nas discrepâncias dos tempos reais de entrega com os estimados, no tempo de preparação de refeições e na relevância do restaurante para o cliente.

Para a resolução da problemática dos novos restaurantes aderentes terem oportunidades justas, considerado um problema *"multi-armed bandit"*, foi utilizado um método de *"upper confidence bound"* (UCB), em que seria atribuído aos restaurantes recentemente registados um parâmetro de UCB relativamente elevado. Este parâmetro seria utilizado em conjunto com os outros fatores-objetivo para determinar as recomendações, oferecendo exposição aos novos restaurantes. Conforme um restaurante vai tendo pedidos, o seu UCB é gradualmente reduzido, transferindo-se, para outros parâmetros objetivos, como a relevância [21,22].

Referências

1. Francesco Ricci, Lior Rokach, Bracha Shapira, Título: Introduction to Recommender Systems Handbook 1st ed, Springer (2011)
2. Supervised and Unsupervised Machine Learning Algorithms, <https://machinelearningmastery.com/supervised-and-unsupervised-machine-learning-algorithms/>. Último acesso:09/10/2018
3. Lops, P., de Gemmis, M., Semeraro, G.: Content-based recommender systems: State of the art and trends. In: F. Ricci, L. Rokach, B. Shapira, P.B. Kantor (eds.) Recommender Systems Handbook, pp. 73–105. Springer Verlag (2011)
4. Reinforcement Learning, <http://pages.cs.wisc.edu/~finton/what-rl.html>. Último acesso:09/10/2018
5. Collaborative filtering: People who bought this also bought..., <https://www.coursera.org/lecture/ml-foundations/collaborative-filtering-people-who-bought-this-also-bought-CdmdR>. Último acesso:09/10/2018
6. Alva and LiuJohan Callvik, Título: Using Demographic Information to Reduce the New User Problem in Recommender Systems, Degree Project In Technology, First Cycle, 15 Credits Stockholm, Sweden 2017
7. Hybrid Recommender Systems, <http://recommender-systems.org/hybrid-recommender-systems/>. Últimos acesso:09/10/2018.
8. Javier Pérez-Marcos¹ and Vivian López, Título: Recommender System based on Collaborative Filtering for Spotify's Users, Department of Computing and Automation, University of Salamanca, Plaza de los Caidos s/n, 37008 Salamanca, Spain
9. Michael Howe, Pandora's Music Recommender
10. Merlinda Sumardi, Jufery, Frenky, Rini Wongso, Ferdinand Ariandy Luwinda, Título: "TripBuddy" Travel Planner with Recommendation based on User's Browsing Behaviour, Computer Science Department, School of Computer Science, Bina Nusantara University, Jl.K.H.Syahdan No. 9 Kemanggisian, Jakarta 11480, Indonesia
11. Joaquim Delgado and Richard Davidson, Título: Knowledge Bases and User Profiling in Travel and Hospitality Recommendar Systems, TripleHop Technologies, Inc, New York, NY, USA, Ski Marketing Corporation, Houston, TX, USA
12. Carl Anderson, Título: A Survef of Food Recommenders, Weight Watchers International, New York, USA

13. Carlos A.Gomez-Urbe and Neil Hunt, Título: The Netflix Recommender System: Algorithms, Business Value, and Innovation
14. Steven Postmus, Título: Recommender system techniques applied to Netflix movie data
15. Frank McSherry and Ilya Mironov, Título: Differentially Private Recommender Systems: Building Privacy into the Netflix Prize Contenders
16. How Netflix's Recommendations System Works, <https://help.netflix.com/en/node/100639>. Último acceso: 07/10/2018
17. Recommendation Systems – How Companies are Making Money, <https://sigmoidal.io/recommender-systems-recommendation-engine>. Último acceso: 07/10/2018
18. Use Cases of Recommendation Systems in Business – Current Applications and Methods, <https://www.techemergence.com/use-cases-recommendation-systems/>. Último acceso: 07/10/2018
19. The magic that makes Spotify's Discover Weekly playlists so damn good, <https://qz.com/571007/the-magic-that-makes-spotifys-discover-weekly-playlists-so-damn-good>. Último acceso: 07/10/2018
20. Dan Claudiu MANOLI, Título: FoodR Recommender System for restaurants, University of Manchester, School of Computer Science
21. Food Discovery with Uber Eats: Recommending for the Marketplace, <https://eng.uber.com/uber-eats-recommending-marketplace/>. Último acceso: 07/10/2018
22. Food Discovery with Uber Eats: Building a Query Understanding Engine, <https://eng.uber.com/uber-eats-query-understanding/>. Último acceso: 07/10/2018