

# Sistemas de Recomendação Aplicados a Serviços de Música, Filmes e Notícias

Sistemas Baseados em Similaridade

Escola de Engenharia, Universidade do Minho

**Resumo.** Um sistema de recomendação é uma ferramenta que procura prever a preferência de um utilizador num dado tema, fornecendo recomendações que o ajudem na tomada de decisão. Estes sistemas utilizam abordagens diferentes, de acordo com a área de aplicação. No presente artigo, iremos focar-nos nas áreas de Música e Filmes e de Notícias, descrevendo produtos que utilizam estes sistemas.

**Palavras-chave:** Sistema de Recomendação · Música · Filmes · Notícias Online · Netflix · Spotify · Google News.

## 1 Enquadramento histórico

Um sistema de recomendação é uma ferramenta tecnológica que procura prever a preferência de um utilizador em relação a um determinado tema [9]. Esta previsão tem como principal objetivo fornecer recomendações ao utilizador que o ajudem na tomada de decisão.

Apesar de um sistema de recomendação que obedece à definição apresentada só ter surgido em meados dos anos 90, formas mais rudimentares destes sistemas eram conhecidas e utilizadas por todas as gerações [10]. Isto porque os seres humanos sempre utilizaram diferentes estratégias quando deparados com a necessidade de decidir: conversando e pedindo a opinião de pessoas próximas, obtendo informação de um especialista numa dada área, consultando livros, etc [5]. No entanto, quanto mais alargado e complexo o conjunto de opções disponíveis, mais difícil se torna o processo de decisão associado a esse conjunto.

Um primeiro aumento significativo na variedade de escolhas teve início no século XIX com a Revolução Industrial, permitindo o desenvolvimento de produtos em massa. Isto tornou diversos produtos bastante mais acessíveis ao público em geral. Contudo, foi a popularização da Internet e a crescente quantidade de informação em circulação que tornou evidente a necessidade de desenvolver sistemas de recomendação mais refinados, que permitissem os utilizadores lidar com o excesso de conteúdos existente.

O primeiro sistema de recomendação, *Tapestry*, surgiu por volta de 1992, no então Centro de Investigação Xerox Palo Alto [5]. As circunstâncias em volta do seu desenvolvimento estavam relacionadas com a quantidade excessiva de *e-mails* a ser recebidos, o que levou os investigadores a criar listas que permitiam filtrar os *e-mails*. Desde então, diferentes sistemas de recomendação têm sido utilizados nas mais diversas áreas, desde o comércio eletrónico, a serviços de partilha

de música e entretenimento. Assim, no presente artigo pretendemos fazer uma introdução a sistemas de recomendação, analisando os diferentes paradigmas e técnicas existentes, com um foco particular em serviços de música, filmes e de notícias.

## 2 Paradigmas de Sistemas de Recomendação

Nesta secção, vamos apresentar as abordagens mais comuns em sistemas de recomendação, tendo por base o artigo [10].

### 2.1 Filtragem Colaborativa

A filtragem colaborativa é um paradigma que se baseia no pressuposto de que se dois utilizadores possuem os mesmos gostos numa área, então é provável que também partilhem gostos numa outra área. Uma forma de descobrir esta semelhança é tendo por base o histórico de *ratings*. Uma vantagem deste tipo de paradigma é que, ao termos muitos utilizadores, as previsões feitas são mais precisas, uma vez que há mais casos de estudo. No entanto, uma desvantagem é que, no caso de um novo utilizador ou conteúdo, o sistema é ineficiente pois não consegue fazer previsões sem uma base anterior. Um exemplo de um produto que utiliza esta abordagem é o Google News, descrito na próxima secção.

### 2.2 Filtragem Baseada em Conteúdo

A filtragem baseada em conteúdo assenta na ideia “Show me more of what I have liked” [10]. Ao contrário do paradigma anterior, esta abordagem não depende da quantidade de utilizadores, mas sim das características do conteúdo, isto é, as recomendações são feitas com base naquilo que o utilizador gostou anteriormente. Uma vantagem deste paradigma é tornar a comparação e categorização de cada conteúdo mais objetiva e eficaz, uma vez que não depende das preferências de outros utilizadores. Por outro lado, uma desvantagem é que, uma vez que novos utilizadores não apresentam um histórico de preferências, torna-se mais difícil apresentar sugestões com base neste método. Também o contrário representa uma desvantagem, isto é, se um utilizador apresentar uma grande diversidade na escolha de conteúdo, torna-se mais difícil fornecer uma recomendação correta. Um exemplo do uso deste paradigma é o caso do Facebook, que recorre a este sistema para recomendar páginas aos utilizadores.

### 2.3 Sistemas de Recomendação Híbridos

Os sistemas de recomendação híbridos são uma combinação dos dois paradigmas referidos anteriormente, criados de forma a colmatar os problemas que cada um tem com as vantagens do outro. Assim, de uma forma geral, é aproveitado o melhor dos dois paradigmas. Uma vantagem clara deste sistema é o facto de conseguir ultrapassar algumas das desvantagens dos paradigmas anteriores. Porém,

uma desvantagem é que a maior parte dos conjuntos de dados não permite a comparação de dois paradigmas. Podemos ver um exemplo deste tipo de sistema no capítulo das aplicações a serviços de música e filmes, mais concretamente quando falarmos da Netflix.

## 2.4 Outros sistemas de recomendação

Para além dos sistemas de recomendação híbridos, existem também os sistemas baseados no conhecimento, sistemas demográficos e sistemas baseados em comunidade. Ao longo deste artigo não iremos aprofundar nenhum destes sistemas, já que não são comuns nos temas que vamos abordar.

## 2.5 Técnicas de *Machine Learning* utilizadas

A cada paradigma de um sistema de recomendação estão associadas algumas técnicas de *Machine Learning* que melhor se adaptam aos mesmos. Entre as técnicas utilizadas, podemos destacar as seguintes: *Matrix factorization-based*, *neighbor-based* e *clustering*. No caso da filtragem baseada em conteúdo, por exemplo, são utilizadas técnicas de classificação e regressão. Apesar da diversidade de métodos existentes, nem sempre é fácil determinar aquela que é mais adequada ao modelo que estamos a construir, sendo este um dos desafios da implementação dos sistemas de recomendação. Além disso, geralmente, as empresas não revelam quais as técnicas que utilizam nos seus sistemas de recomendação, pelo que na construção de um novo sistema, é sempre necessário avaliar e testar diferentes métodos para ver qual é o mais adequado ao nosso contexto.

## 3 Aplicações a Serviços Noticiosos

Ao longo das últimas décadas, foi possível verificar um grande *shift* no consumo de notícias, passando de um consumo feito primariamente em papel, para o digital. Esta mudança deve-se maioritariamente a dois fatores: a ubiquidade da Internet e o desenvolvimento tecnológico dos dispositivos móveis [11]. A primeira, levou a um aumento não só do número de consumidores, como também do número de fontes. A segunda, permitiu que a consulta de notícias pudesse ser feita em qualquer altura e lugar. Adicionalmente, a constante atualização da localização geográfica dos utilizadores permitiu elevar ainda mais o grau de personalização associado ao serviço.

Esta rápida disponibilidade da informação levou a um aumento exponencial da quantidade de notícias em circulação, tornando a sua filtragem e seleção cada vez menos factíveis. Assim, tornou-se evidente a necessidade de ter sistemas de recomendação eficazes, capazes de responder às necessidades dos consumidores e otimizar a procura das notícias mais relevantes, dentro da janela temporal adequada. Este é a dificuldade fundamental na implementação destes serviços. Além disto, existem também outros desafios inerentes a estes sistemas, nomeadamente: o curto ciclo de vida das notícias, as preferências dependentes do contexto (geográfico, socioeconómico, etc) e a diversidade de notícias existentes [1].

Tipicamente, nos serviços de notícias é utilizado um sistema de avaliação dos artigos, que permite obter o *feedback* por parte dos utilizadores. Isto pode ser feito de uma forma explícita, em que o utilizador atribui uma pontuação ao artigo visualizado, a partir da qual são feitas recomendações de artigos semelhantes aos que apresentam um *feedback* positivo (abordagem baseada em conteúdo). Por outro lado, essa avaliação pode servir para relacionar utilizadores com pontuações semelhantes, dando sugestões com base nessas semelhanças (abordagem colaborativa). No entanto, esta avaliação também pode ser obtida de uma forma implícita, com base no histórico de cliques do utilizador (neste caso, um clique num artigo é interpretado como sendo *feedback* positivo) [11]. Esta é a abordagem utilizada pelo Google News, que iremos apresentar nesta secção.

### 3.1 Estudo de Caso: Google News

O Google News é um agregador de notícias desenvolvido pela Google, que fornece um fluxo de notícias recentemente publicadas por milhares de diferentes fontes. Estas notícias estão organizadas por categorias abrangentes (como “Mundo”, “Desporto”, “Entretenimento”, etc), sendo que cada categoria tem uma secção específica no *site*. Este serviço está disponível em diferentes línguas e versões de acordo com o país de consulta. Nesta secção, vamos falar do sistema descrito em [6].

Como já foi mencionado, o Google News oferece uma personalização baseada no histórico de cliques do utilizador, sendo esta uma funcionalidade que tem de ser ativada explicitamente nas definições de conta. Um primeiro sistema de recomendação foi estabelecido utilizando filtragem colaborativa, através do qual os utilizadores recebiam sugestões de notícias com base em utilizadores com histórico de cliques semelhantes. Este método tem duas desvantagens: a primeira, conhecida por *first-rater problem*, resume-se ao facto de que notícias que ainda não foram lidas, não podem ser recomendadas. Uma vez que este método necessita de algumas horas para recolher e processar um número de cliques suficiente para apresentar uma recomendação, cria-se um atraso entre o surgimento da notícia e a sua sugestão [6]. A segunda desvantagem prende-se com a variabilidade associada a cada utilizador, uma característica que este método pode ter dificuldade em incorporar nas suas recomendações (isto é, notícias de um certo tema que tenham muitos cliques serão sempre recomendadas, mesmo que o utilizador não tenha mostrado interesse nesse tema em particular).

No estudo em causa, chegou-se à conclusão de que as notícias do interesse dos utilizadores são influenciadas pelas tendências regionais. Assim, os interesses do utilizador são decompostos em dois grupos: os seus interesses genuínos e os que são influenciados pelas tendências de notícias locais. O método desenvolvido assenta numa *framework* Bayesiana, seguindo os seguintes passos: primeiro, o sistema faz uma previsão dos interesses genuínos do utilizador isoladamente, fazendo uso do seu histórico de cliques; de seguida, uma série de previsões feitas anteriormente é combinada de forma a gerar uma previsão mais precisa dos interesses genuínos do utilizador; por fim, o sistema prevê os interesses atuais

do utilizador, cruzando os seus interesses genuínos com as tendências atuais de notícias na sua região.

Como sabemos, a Google procura ativamente melhorar os seus produtos, pelo que os seus sistemas de recomendação estão em constante revisão e atualização. Nesta secção, explorámos uma das possíveis abordagens num serviço de notícias *online*.

## 4 Aplicações a Serviços de Música e Filmes

Assim como na aplicação acima, com o passar dos anos a sociedade foi abandonando gradualmente o consumo de música e filmes no formato físico e adotando novas formas de o fazer usando serviços de partilha legal dos mesmos. Ao contrário dos serviços noticiosos, esta transição ocorreu a um nível muito mais rápido e em maior escala, fazendo com que os serviços deste tipo de conteúdo tivessem que se adaptar mais rapidamente às necessidades dos consumidores.

Com isto, vamos focar o nosso estudo nos dois gigantes serviços de partilha de filmes e música, respetivamente: Netflix e Spotify.

### 4.1 Estudo de Caso: Netflix

A Netflix é uma empresa que fornece um serviço de partilha de séries e filmes *online* aos seus assinantes. Fundada em 1997 nos Estados Unidos da América como uma empresa de entregas de DVD's pelo correio, esta empresa soube adaptar-se às mudanças da sociedade e atualmente disponibiliza os seus serviços de partilha de filmes em quase todos o mundo.

Visto que o seu lucro baseia-se nas assinaturas dos seus clientes, é importante manter todos os seus assinantes satisfeitos com o serviço prestado. É neste âmbito que entra o mecanismo de recomendação da Netflix, visto que, através das recomendações que o servidor fornece, é possível aconselhar novos filmes e séries aos clientes, prendendo o seu interesse e atenção no conteúdo oferecido. O sistema de recomendação atual da Netflix manipula vários dados de forma a fazer um emparelhamento perfeito e aconselhar da melhor maneira os filmes e séries que o cliente pode gostar de assistir no futuro. Os dados guardados e tratados pelo algoritmo de recomendação são:

**Os filmes/séries visualizados anteriormente:** Desta forma, é possível recomendar filmes com temas semelhantes aos assistidos anteriormente.

**Pontuação dada aos filmes:** Quando um cliente avalia um filme com baixa pontuação, é provável que outro filme que se enquadra na mesma categoria obtenha também uma pontuação baixa pelo assinante. Assim, o serviço de recomendação não aconselhará esse conteúdo. Uma avaliação alta tem o efeito oposto.

**Clientes agrupados por gostos:** O sistema pretende aconselhar a um cliente um filme que um segundo cliente com gostos similares tenha assistido e tenha dado pontuação alta.

**Qual o dispositivo que utiliza para fazer a visualização, durante quanto tempo a faz e a que hora:** Este sistema guarda também estes dados de forma a fazer uma avaliação mais precisa. Por exemplo, se um assinante assiste regularmente a um filme infantil durante a manhã, é provável que o mesmo deseje continuar a visualizar filmes do mesmo género de manhã e não durante a noite. E se assiste regularmente a filmes no *smartphone*, então é preciso ter alguma cautela em aconselhar outro tipo de filme em que a qualidade da imagem e do som seja crucial para apreciar o conteúdo.

Após uma análise do tipo e da forma como os dados são tratados pela Netflix, é possível perceber que utilizam um serviço de recomendação híbrido, adotando, assim, as suas vantagens, mas também as desvantagens. A grande desvantagem do seu serviço de recomendação é o chamado **cold start** - arranque lento, isto é, quando um novo cliente faz o registo na plataforma, o serviço não possui nenhuma das informações referidas em cima. Para contornar de forma célere esta situação, o serviço de recomendação apresenta um conjunto de títulos aleatórios para o cliente selecionar os que mais gosta. De seguida, a plataforma utiliza estes dados para aconselhar novos títulos, sendo que a partir do momento em que o cliente começa a usufruir do conteúdo, os novos dados que o sistema vai adquirindo sobrepõem-se aos iniciais. No entanto, se na altura do registo o assinante optar por ignorar este passo, o serviço de recomendação vai apresentar um conjunto de títulos que são populares tanto na zona geográfica do cliente como mundialmente.

Além do algoritmo de recomendação que utilizado (mas não revelado), a empresa acredita que a forma como o conteúdo é apresentado aos clientes influencia também as escolhas. Desta forma, a gigante americana engloba no seu mecanismo de recomendação não só o algoritmo de recomendação, mas também uma interface intuitiva e apelativa. A Netflix estima que 80% do conteúdo visionado provém do mecanismo de recomendação, sendo a percentagem restante derivada da pesquisa espontânea do cliente.

Por fim, de forma a compreender a importância que a empresa atribui ao mecanismo de recomendação, a mesma deu início a um concurso denominado por “Netflix Prize”, com o objetivo de encontrar o melhor algoritmo de filtragem colaborativa. Com este prémio, a empresa pretendia conceber um algoritmo capaz de prever as avaliações futuras a filmes, com base nas avaliações passadas atribuídas a filmes com características idênticas. A Netflix ofereceu um conjunto de 100.480.507 avaliações que 480.189 usuários deram a 17.770 filmes. Quem conseguisse prever as avaliações com a menor margem de erro possível ganhava 1 milhão de dólares. O concurso terminou em 2009 com a empresa BellKor’s Pragmatic Chaos ter sido a vencedora com um erro máximo de 0.8567%.

## 4.2 Estudo de Caso: Spotify

Spotify é uma empresa que fornece um serviço de partilha de músicas aos seus clientes. Ao contrário da Netflix, esta plataforma tem uma versão paga para os seus assinantes e gratuita para o público em geral. Fundado pela *startup* Spotify AB em Estocolmo em 2006, foi lançado no dia 7 de outubro de 2008. A empresa

sueca alargou os seus serviços a todo o mundo, sendo neste momento e no seu ramo, o serviço mais popular e mais usado mundialmente.

Apesar de ter uma versão grátis com o intuito de mostrar a capacidade da plataforma, o Spotify obtém os rendimentos a partir dos seus assinantes, procurando, através do seu mecanismo de recomendação, oferecer *playlists* personalizadas ao cliente de forma a que esta consiga obter o maior proveito do serviço.

Todas as plataformas que utilizem mecanismos de recomendação primam pela capacidade de oferecer uma experiência única ao cliente, assim sendo, o Spotify orgulha-se das suas ofertas únicas. Todos os dias, a plataforma atualiza um conjunto de 6 *playlists* denominadas por *Daily Mixes*, onde oferece músicas que o serviço de recomendação estima que estejam no top das preferências a usufruir. São uma mistura de músicas mais ouvidas com músicas menos ouvidas mas com características semelhantes. Além disto, também prepara uma *playlist* semanal denominada por “Descobertas da Semana”, na qual oferece um conjunto de músicas escolhidas especificamente para cada cliente, que ele ainda não ouviu mas poderá gostar. Esta seleção é efetuada através das músicas que o utilizador e outros utilizadores com gostos de semelhantes (segundo o algoritmo de recomendação) ouviram recentemente. A última oferta de destaque deste serviço de recomendação é a *playlist* com músicas novas, isto é, que foram adicionadas recentemente á base de dados da plataforma. Estas músicas são apresentadas com base nos parâmetros de similaridade com as músicas preferidas do ouvinte.

Segundo o Spotify, o seu sistema de recomendação manipula os seguintes dados, de forma a ensinar o seu algoritmo: a **acústica**, o **ritmo de dança**, a **energia**, a **instrumentalidade**, o **nível de ruído ao vivo**, o nível de **discurso**, o **nível de batidas por minuto** e o **nível de emoção**.

Assim como o caso de estudo anterior, o Spotify tem de ultrapassar alguns desafios impostos pelo desenvolvimento do mecanismo de recomendação. Do mesmo modo que a Netflix, esta plataforma sofre do problema de **cold start**. Ou seja, quando um cliente é recente no serviço, poucas informações dispomos sobre o mesmo, por isso é complicado enquadrá-lo num grupo de recomendação ou saber quais são os seus gostos.

## 5 Vantagens dos Sistemas de Recomendação

Nas secções anteriores, pudemos constatar a importância e utilidade dos sistemas de recomendação. Neste secção, iremos explicitar algumas das vantagens destes sistemas, tanto do ponto de vista do promotor do serviço, como do alvo.

Relativamente ao promotor, a mais relevante será a receita, visto que, com este tipo de sistemas, o alvo da recomendação irá visualizar produtos que não conheceria de outra forma. Assim, a quantidade de produtos que o cliente irá adquirir pode aumentar, uma vez que fica a conhecer novos itens. Relacionado com isto está também a satisfação dos clientes, sendo algo bastante importante para quem está a promover o sistema.

Outra vantagem é a retenção dos clientes, pois existem certas áreas profissionais que envolvem uma pesquisa/compra exaustiva *online*, necessitando de um sistema de filtragem eficaz. Assim, se os clientes puderem ter recomendações apenas numa área específica, isto vai não só ajudá-los a poupar bastante tempo, como também vai permitir que conheçam outros materiais semelhantes. A boa experiência de utilizador aumenta a probabilidade de os clientes voltarem a visitar esse *site*.

Por fim, os sistemas de recomendação ajudam também na manutenção organizacional de um *site*, visto que a maior parte dessa manutenção consiste em manter o sistema de navegação alinhado com as necessidades de mudança dos utilizadores. Com a ajuda destes sistemas, este tipo de manutenção é bastante reduzida, pois de acordo com a atividade do utilizador, o sistema vai-lhe recomendar opções de navegação, poupando, desta forma, *staff time*.

De seguida, apresentamos uma tabela com as vantagens que estes sistemas oferecem a nível de negócio.

Vantagens em negócios	
Receita	5% - 15% de aumento
Compromisso	12%-18% dos visitantes ficam comprometidos com recomendações de produtos
Valor geral das ordens	30% - 70% de aumento
Itens por ordem	20% - 40% de aumento
Taxa de Conversão	2 - 4x de aumento
Poupa tempo no <i>staff</i>	Devido à eliminação de esforços em gerir conteúdos

**Tabela 1.** Vantagens em contexto de negócios. Retirado de [2].

Relativamente ao alvo do serviço, é através da análise das suas utilizações atuais, e tendo em conta o histórico das navegações que ele efetuou anteriormente, que estes sistemas vão recomendar (à partida) algo útil para o cliente. Desta forma, ele evita trabalho desnecessário à procura de outros produtos dentro da mesma área. Além disso, o cliente também pode encontrar algo que não conseguiria pesquisando por si, sendo a descoberta outro benefício. Outra vantagem é o facto de poder estar a par das novidades, uma vez que os sistemas de recomendação têm de estar atualizados, permitindo o público alvo ter conhecimento de informação não obsoleta. Por último, a privacidade é algo que será assegurado, visto que os utilizadores não têm que fornecer qualquer tipo de informação pessoal.

## 5.1 Música vs. Filmes

Nos sistemas de recomendação, apesar destes dois temas estarem intrinsecamente relacionados, apresentam ainda algumas vantagens (ou desvantagens) entre eles. Apresentamos, de seguida, uma comparação dos serviços nestas duas áreas.



**Duração dos itens:** O facto da duração de uma música ser muito menor que a duração de um filme faz com que o tempo de consumo de um filme seja mais elevado, levando a que os itens musicais sejam mais “descartáveis”.

**Magnitude dos itens:** A escalabilidade é também um fator a considerar, visto que os catálogos de música se apresentam na ordem dos milhões, em comparação com o catálogo de filmes, que será muito mais reduzido. Isto implica uma menor possibilidade de escolha no que toca a filmes.

**Consumo sequencial:** Por norma, o público alvo irá apresentar um consumo da música de uma forma muito mais sequencial do que em relação aos filmes, ou seja, irá ouvir várias músicas seguidas, e não ver a mesma quantidade de filmes seguidos.

**Recomendação de itens anteriores:** Esta é uma grande vantagem da música em relação aos filmes, pois é possível repetir a mesma música ao público alvo. O mesmo já não acontece com os filmes, pois a probabilidade do público alvo querer repetir o mesmo filme é bastante reduzida.

**Emoções:** A relação entre as emoções e a música é altamente conhecida e facilmente relacionável com qualquer pessoa, pois dependendo da emoção de cada um, a sua escolha musical num dado momento vai ser diretamente influenciada. Isto apresenta um problema, visto que os sistemas de recomendação não conseguem prever quando alguém está alegre ou triste e ter isso em consideração numa recomendação. Já no caso dos filmes, a emoção não tem um impacto tão direto, uma vez que os estilos preferidos de filmes não variam tanto.

**Contexto:** A *playlist* de uma pessoa que vai sair à noite com os amigos será totalmente diferente da *playlist* que a mesma pessoa irá escolher quando quer ir praticar desporto. O contexto é algo que, apesar de também estar presente nos filmes, varia muito mais na área da música.

## 5.2 Serviços noticiosos

Em relação aos serviços noticiosos, as vantagens destacadas no início desta secção são as que também se aplicam neste caso. Como vimos, esta área enfrenta alguns desafios específicos, devido à necessidade de realizar diariamente uma filtragem eficiente e atempada de uma enorme quantidade de informação.

## 6 Conclusões

Neste artigo, introduzimos os sistemas de recomendação, bem como alguns conceitos associados aos mesmos. Vimos que estes sistemas são ferramentas tecnológicas que procuram fornecer recomendações ao utilizador sobre um dado produto, com base em previsões feitas acerca do mesmo. A sua utilidade torna-se evidente na atual sociedade, tendo em conta a grande diversidade e quantidade de conteúdos em circulação.

Em primeiro lugar, procuramos aprofundar o conhecimento sobre os paradigmas dos sistemas de recomendação. Os paradigmas abordados foram: o de filtragem colaborativa, que consiste no pressuposto de que se dois utilizadores

possuem os mesmos gostos numa área, então é provável que também partilhem gostos numa outra área; o da filtragem baseada em conteúdo, que assenta no pressuposto de não depender da quantidade de utilizadores, mas sim das características do conteúdo; o paradigma de recomendações híbrido, que cruza os dois paradigmas referidos anteriormente. Cada um destes métodos tem vantagens e desvantagens associadas, que foram exploradas na secção anterior. Em segundo lugar, analisámos duas áreas de aplicação entre as inúmeras existentes: os serviços de partilha de músicas e filmes, e os serviços noticiosos. Para cada um destes casos, estudamos produtos concretos, analisando as abordagens e funcionalidades dos seus sistemas de recomendação.

Dada a importância que estes sistemas têm na forma como processamos informação e consumimos produtos atualmente, prevemos que a investigação nesta área dê origem a sistemas cada vez mais eficientes, fazendo uso de diferentes técnicas de *Machine Learning*, mesmo com os desafios inerentes a cada área.

## Referências

1. Beck, P., Blaser, M., Michalke, A., Lommatzsch, A.: A system for online news recommendations in real-time with apache mahout. Working Notes of the 8th International Conference of the CLEF Initiative **1866** (2017)
2. Bowden, J.: What A Product Recommendation Engines Mean to Business. <https://www.business2community.com/strategy/product-recommendation-engines-mean-business-0893268>, consultado a 8-10-2018.
3. Carlos A. Gomez Uribe, N.H.: The netflix recommender system: Algorithms, business value, and innovation. ACM Trans. Manage. Inf. Syst. 6, 4 **13** (Dezembro 2015)
4. Faustino, E.: Netflix: Sistemas de recomendação inteligentes. Revista Tecer n°16 **9** (Maio 2016)
5. Jannach, D., Zanker, M., Felfernig, A., Friedrich, G.: Recommender Systems: An Introduction. Cambridge University Press, New York, NY, USA, 1st edn. (2010)
6. Liu, J., Dolan, P., Pedersen, E.: Personalized news recommendation based on click behavior. International Conference on Intelligent User Interfaces, Proceedings IUI pp. 31–40 (02 2010)
7. Markus Schedl, Hamed Zamani, C.C.Y.D.M.E.: Current challenges and visions in music recommender systems research (Março 2018)
8. Netflix: Funcionamento do sistema de recomendações da Netflix. <https://help.netflix.com/pt-pt/node/100639/>, consultado a 6-10-2018.
9. Ricci, F., Rokach, L., Shapira, B., Kantor, P.B.: Recommender Systems Handbook. Springer, Boston, MA, USA, 1st edn. (2011)
10. Sharma, R., Singh, R.: Evolution of recommender systems from ancient times to modern era: A survey. Indian Journal of Science and Technology **9** (05 2016)
11. Viana, P.: A hybrid recommendation system for news in a mobile environment pp. 1–9 (06 2016)